

NewsAnalyzer

Система поиска и анализа научных статей

Настольное приложение на Python + CustomTkinter с локальным ИИ (Ollama).
Объединяет международные академические базы данных и русскоязычные научные ресурсы в единый интерфейс с поддержкой суммаризации, перевода и сохранения статей.

Версия документа: 1.0 · Май 2026

1. Общее описание проекта

NewsAnalyzer — это десктопное приложение для исследователей, аспирантов и студентов, которые работают с научной литературой. Приложение позволяет искать статьи сразу из нескольких источников, скачивать их, генерировать краткие изложения с помощью локальной языковой модели, переводить запросы и фильтровать результаты — всё это без выхода в платные сервисы и без передачи данных в облако.

Ключевые принципы:

- Автономность — локальный AI (Ollama), без подписок и API-лимитов
- Лёгкость — работает на любом железе без GPU, модели $\leq 3B$ параметров
- Конфиденциальность — данные хранятся локально в SQLite
- Мультиязычность — русскоязычные и международные базы данных в одном окне

2. Технологический стек

Слой	Технология	Назначение
GUI-фреймворк	CustomTkinter 5.2.2	Современный вид на Tkinter; тема warm-cream
Языковая модель	Ollama + qwen2.5:3b	Суммаризация и перевод, локально
HTTP-клиент	requests	arXiv, PubMed, Semantic Scholar, SibAC
HTTP-клиент TLS	curl-cffi	Обход TLS-блокировки на eLibrary.ru
HTML-парсер	BeautifulSoup4 + lxml	Скрапинг веб-страниц
Парсер статей	newspaper4k	Извлечение текста из URL
База данных	SQLite (WAL-mode)	Пользователи, статьи, история, настройки
PDF-генерация	ReportLab	Экспорт документации

3. Архитектура

Приложение организовано в три пакета с чёткими зонами ответственности:

Пакет	Ответственность	Ключевые файлы
core/	Поиск, скрапинг, AI, скачивание	api_client, scrapers, translator, summarizer, downloader
db/	Персистентность, аутентификация, настройки	database.py, __init__.py
ui/	Интерфейс пользователя	app, search_tab, settings_tab, theme, login

Поток запуска: main.py → init_db() → LoginWindow → App (табы).

Поиск (фон): threading.Thread(daemon=True) → .after(0, callback) на результаты.

4. Источники данных

Приложение поддерживает 8 источников научных статей, разделённых на два типа.

4.1 Международные API (вкладка «Картотека»)

Источник	Метод	Особенности
arXiv	REST API (XML)	Бесплатно, без ключа; физика, мат., CS, AI; поддержка авторского поиска
PubMed (NCBI)	E-utilities API	Биомедицинские статьи; ключ опционален (повышает лимит)
Semantic Scholar	REST API (JSON)	Кросс-дисциплинарный; ключ опционален; открытый full-text

4.2 Скраперы (вкладка «Разведка»)

Сайт	Метод скрапинга	Замечание
CyberLeninka.ru	POST /api/search (внутренний JSON API)	Работает без авторизации; аннотации с -тегами
SibAC.info	GET /search/node (Drupal CMS)	allow_redirects=False обязателен; РИНЦ-статьи
CyberPedia.su	Яндекс.Поиск по сайту (searchid=2392445)	Учебные конспекты; без авторизации
Moluch.ru	SSR-обход /archive/NNN/ (keyword в заголовке)	«Молодой учёный»; РИНЦ; до 200 ст/выпуск
eLibrary.ru	curl-cffi + логин POST /start_session.asp	Требует бесплатный аккаунт; полная РИНЦ-база

Все скраперы возвращают единый объект Article (title, authors, url, year, source, abstract), что позволяет отображать карточки единообразно вне зависимости от источника.

5. Модуль поиска (SearchTab)

Центральный модуль приложения (~1 200 строк). Содержит две под-вкладки:

5.1 Картотека

- Поисковая строка с историей (dropdown при фокусе, shared с Разведкой)
- Переключатель режима: тема / автор (при авторском режиме отправляет запрос в поля авторов API)
- Фильтры: выбор источников (arXiv, PubMed, Semantic Scholar), лимит результатов (5/10/20/50)
- Поиск в отдельном потоке, UI не блокируется
- Карточка статьи: заголовок, авторы, год, источник с цветным чипом, аннотация
- Действия на карточке: скачать (PDF или TXT), суммаризировать, перевести на русский

5.2 Разведка

- Левая панель: чекбоксы сайтов, режим тема/автор, задержка (с динамической подсказкой $\geq N$ сек), количество статей (10/30/100)
- Правая панель: те же карточки статей с аннотацией источника
- eLibrary отключён по умолчанию — активируется только после ввода логина в Настройках
- Аннотации источников: SibAC («выпуск журнала»), CyberPedia («учебный материал»), МолодойУчёный («РИНЦ»), eLibrary («полная РИНЦ-база»)

6. Функции локального ИИ (Ollama)

Все AI-функции используют локальный сервер Ollama на порту 11434. Модель по умолчанию — qwen2.5:3b (≈2 GB VRAM или RAM).

Функция	Класс	Описание
Суммаризация	Summarizer	Текст разбивается на чанки по 3000 символов, каждый суммаризируется, финал
Перевод запроса	Translator	Переводит поисковый запрос с русского на английский перед отправкой в arXiv/
Перевод текста	Translator	Переводит полный текст статьи на русский язык

При недоступности Ollama (сервер не запущен) функции AI деградируют gracefully: кнопки остаются активными, при нажатии показывается ошибка без краша приложения.

7. Скачивание статей (downloader.py)

Модуль определяет стратегию скачивания по полю `Article.source`:

Источник	Формат	Стратегия
arXiv	PDF	Замена <code>/abs/</code> → <code>/pdf/</code> в URL, прямое скачивание
PubMed	TXT	E-utilities API, извлечение абстракта и метаданных
Semantic Scholar	PDF / TXT	<code>openAccessPdf.url</code> из API; fallback — TXT с абстрактом
CyberLeninka	PDF / TXT	Поиск <code></code> на странице статьи; TXT-fallback
SibAC	PDF	Поиск <code>/archive/*.pdf</code> в <code>.sib-article</code> ; скачивает весь выпуск
Другие	TXT	generic: newspaper4k парсит текст статьи из URL

Файлы сохраняются в папку `НайденныеСтатьи/` в директории приложения. Запись о скачивании сохраняется в таблицу `articles`.

8. База данных

SQLite в режиме WAL. Файл `newsanalyzer.db` создаётся автоматически при первом запуске.

Таблица	Назначение	Ключевые поля
users	Учётные записи	username, password_hash (salt:sha256), is_admin
articles	Скачанные статьи	url, title, source, file_path, user_id, summary, embedding
tags / article_tags	Теги статей (M:N)	name, article_id, tag_id
persons	Персоны/авторы для слежения	name, description, user_id
person_mentions	Упоминания персон в статьях	person_id, article_id, context

search_history	История поисковых запросов	query, results_count, user_id, searched_at
app_settings	Настройки приложения (key-value)	key (PK), value — хранит elibrary_login/password

9. Аутентификация и настройки

Авторизация: логин/пароль, хеширование SHA-256 с солью. При первом запуске создаётся учётная запись admin/admin. При первом входе нового пользователя — обязательная установка пароля.

Вкладка «Настройки» включает три раздела:

- Пользователи — создание, удаление, сброс пароля (только для admin)
- LLM (Ollama) — выбор модели, URL сервера
- API-ключи — учётные данные eLibrary.ru (логин + пароль, сохраняются в app_settings)

10. Детали пользовательского опыта (UX)

Функция	Реализация
Контекстное меню (ПКМ)	Вырезать / Копировать / Вставить / Выделить всё — на всех полях ввода
Ctrl+A	Выделение всего текста в поле ввода
История поиска	Dropdown при фокусе; 10 последних уникальных запросов; shared между Картотекой и Разв
Динамическая подсказка	В поле задержки: «□ рекомендуется ≥N сек» или «□ рекомендуется ≥N сек»
Тема оформления	Warm-cream palette: BG=#fbf8f3, ACCENT=#d97757; цветные чипы источников
Цветовые чипы источников	arXiv (оранж), PubMed (зел.), Semantic Scholar (серый), CyberLeninka (синий), SibAC (жёлт.)
Фоновые операции	Поиск, скачивание, суммаризация — в даемон-потоках, UI не блокируется

11. Структура файлов проекта

Файл	Строк	Назначение
main.py	45	Точка входа: БД, LoginWindow, App
summary.py	82	Утилита суммаризации (standalone)
core/api_client.py	250	Клиент arXiv / PubMed / Semantic Scholar
core/scraper.py	53	Парсер произвольных URL (newspaper4k)
core/translator.py	119	Перевод через Ollama

core/summarizer.py	84	Суммаризация через Ollama
core/downloader.py	276	Скачивание PDF/TXT по источнику
core/cyberleninka.py	198	Скрапер CyberLeninka (JSON API)
core/sibac.py	124	Скрапер SibAC (Drupal search)
core/cyberpedia.py	120	Скрапер CyberPedia (Яндекс site search)
core/moluch.py	199	Скрапер Молодой учёный (SSR архив)
core/elibrary.py	231	Скрапер eLibrary (curl-cffi + auth)
db/database.py	353	SQLite ORM: схема, миграции, CRUD
db/___init___py	18	Публичный API пакета db
ui/theme.py	163	Дизайн-система: цвета, шрифты, виджеты
ui/app.py	207	Главное окно, таб-бар
ui/login.py	110	Окно входа
ui/set_password_window.py	165	Диалог первичной установки пароля
ui/search_tab.py	1 202	Поиск: Картотека + Разведка (главный модуль)
ui/settings_tab.py	473	Настройки: пользователи, eLibrary, Ollama
ui/results_tab.py	63	Результаты (заглушка)
ui/digest_tab.py	86	Дайджест (заглушка)
ui/compare_tab.py	66	Сравнение (заглушка)
ui/analytics_tab.py	61	Аналитика (заглушка)
ui/persons_tab.py	146	Персоны (частично)
Итого	~5 900	~400 строк Python-кода

12. Зависимости

Пакет	Версия	Для чего
customtkinter	5.2.2	GUI-фреймворк
requests	любая	HTTP для API и большинства скраперов
curl-cffi	любая	Chrome-TLS для eLibrary.ru
beautifulsoup4	любая	Парсинг HTML
lxml	любая	Быстрый XML/HTML-парсер для bs4
newspaper4k	любая	Извлечение текста статей

reportlab	4.x	Генерация PDF (этот документ)
Ollama	локальный	LLM-сервер (внешний, не pip)
Python	3.10+	Требования: match/case, union types

13. Статус реализации

13.1 Полностью рабочий функционал

- Авторизация и управление пользователями
- Поиск в Картотеке: arXiv, PubMed, Semantic Scholar (тема + автор)
- Поиск в Разведке: CyberLeninka, SibAC, CyberPedia, Молодой учёный, eLibrary
- Скачивание статей (PDF/TXT) с сохранением в БД
- Суммаризация и перевод через Ollama
- История поиска (shared между вкладками)
- Контекстное меню и Ctrl+A во всех полях ввода
- Динамическая подсказка задержки скрапера
- Цветовые чипы и аннотации источников
- eLibrary: авторизация через curl-cffi, сохранение credentials в БД

13.2 Заглушки (UI создан, логика не реализована)

- Вкладка «Результаты» — список скачанных статей (таблица есть, данные не подгружаются)
- Вкладка «Дайджест» — генерация сводки по набору статей
- Вкладка «Сравнение» — side-by-side сравнение двух статей
- Вкладка «Аналитика» — графики по тематикам и годам
- Персоны — интеграция с поиском упоминаний
- Semantic Scholar / PubMed — поля для API-ключей, но ключи не применяются
- Резервное копирование БД

14. Запуск приложения

Установка зависимостей:

```
pip install customtkinter requests curl-cffi beautifulsoup4 lxml newspaper4k reportlab
```

Запуск Ollama (в отдельном терминале):

```
ollama serve
ollama pull qwen2.5:3b
```

Запуск приложения:

```
python main.py
```

При первом запуске создаётся newsanalyzer.db и учётная запись admin / admin. Рекомендуется сменить пароль в Настройках → Пользователи.